Collaborate.
Automate.
Innovate.

Évaluer les LLMs: ce que mesurent et ratent les benchmarks

Presented by Justine Gehring | Gologic

For Confoo 2026

GOLOGIC

Justine Gehring

Head of AI Business Line

An expert in artificial intelligence, I develop AI solutions aimed at improving the productivity of IT teams. Educated at McGill and Mila, I specialized in Machine Learning for Code. As a speaker and co-author of the book "AI for Mass-Scale Code Refactoring and Analysis" (O'Reilly, 2024), I also serve on the program committee of TechDebt and will be responsible for the industry track in April 2026.

Imaginez que vous êtes un prof qui enseigne coding 101.

Comment est-ce que vous évaluez si un élève sait coder?

- multiple choice questions
- short answers
- what does this code print?
- coding assignments

What if they have almost perfect recall memory...?

On y va avec les bases… comment est-ce qu'on train un modèle d'IA?

```
import gradio as gr

with gr.Blocks() as demo:
    name_box = gr.Textbox(label="Name")
    age_box = gr.Number(label="Age", minimum=0, [      ]=100)
    symptoms_box = gr.CheckboxGroup(["Cough", "Fever", "Runny Nose"])
    submit_btn = [  ].Button("Submit")

    with gr.Column(visible=False) as output_col:
        diagnosis_box = gr.Textbox(label=[          ])
        patient_summary_box = gr.Textbox(label="Patient Summary")
```

github

textbooks

....

all of the internet

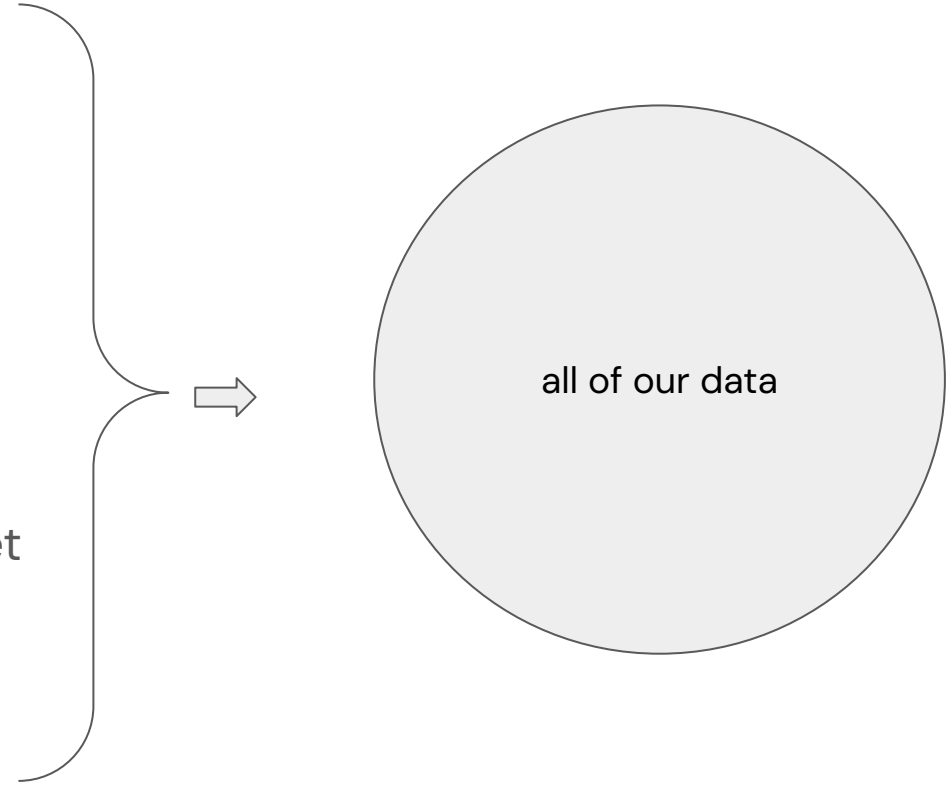

github

textbooks

….

all of the internet

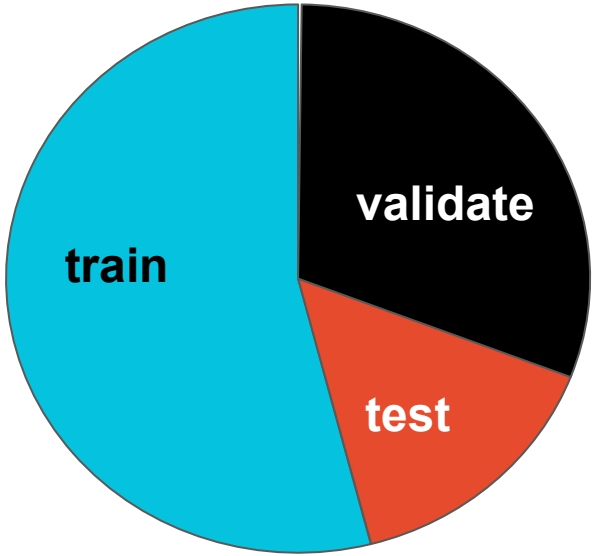

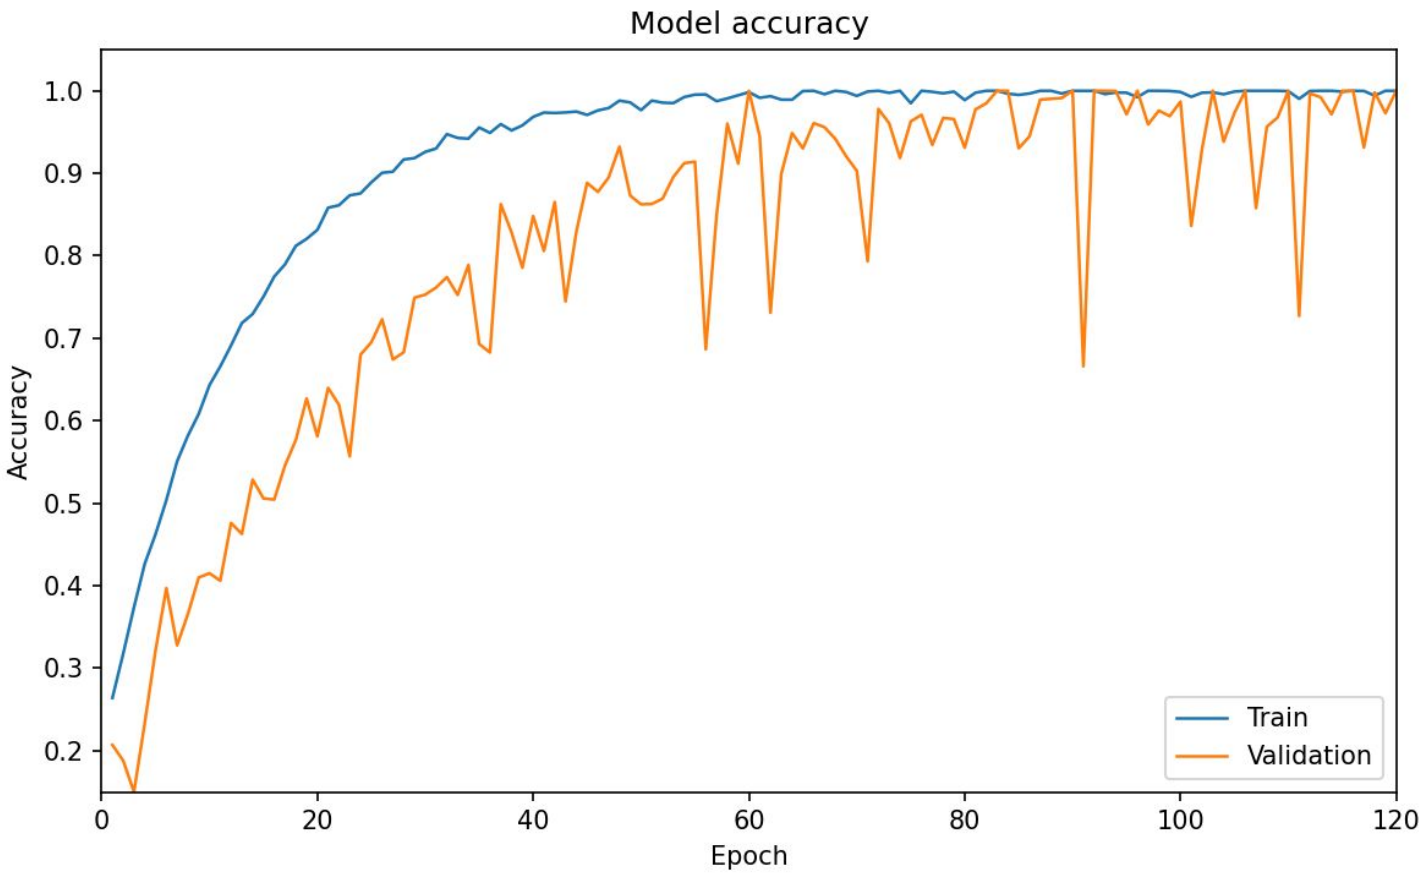
Model accuracy
Accuracy
Epoch
Train
Validation
1.0
0.9
0.8
0.7
0.6
0.5
0.4
0.3
0.2
0
20
40
60
80
100
120

Donc on peut évaluer si un modèle a bien appris en général…

Metrics:

- Accuracy
- Recall
- Perplexité

Donc on peut évaluer si un modèle a bien appris en général…

Metrics:

- Accuracy
- Recall
- Perplexité

La façon la plus simple de tester

Prompt:
“Comment est-ce que je code une methode pour retourner le dernier objet dans une liste en python. Appelle la méthode ‘return_last’. ”

AI Answer:
“def return_last (array):
return array[-1]”

Golden Answer:
“def return_last (array):
n = len(array)
return array[n]”

Exact match

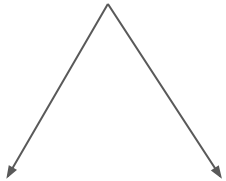

0 1

La façon la plus simple de tester

Prompt:
“Comment est-ce que je code une methode pour retourner le dernier objet dans une liste en python. Appelle la méthode ‘return_last’. ”

AI Answer:
“def return_last (array):
return array[-1]”

Golden Answer:
“def return_last (array):
n = len(array)
return array[n]”

how many “words” match (%)

0 – 100 %

La façon la plus simple de tester

AI Answer:
“def return_last (array):
k = len(array)
return array[k]”

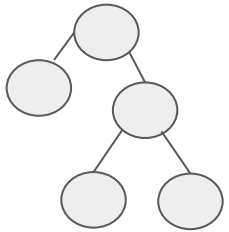

Golden Answer:
“def return_last (array):
n = len(array)
return array[n]”

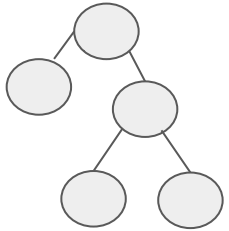

how many “nodes” match (%)

0 – 100 %

HumanEval

Prompt

```
from typing import List


def has_close_elements(numbers: List[float],
threshold: float) -> bool:
""" Check if in given list of numbers, are any
two numbers closer to each other than
given threshold.
>>> has_close_elements([1.0, 2.0, 3.0], 0.5)
False
>>> has_close_elements([1.0, 2.8, 3.0, 4.0,
5.0, 2.0], 0.3)
True
"""
```

A potential answer

```
for idx, elem in
enumerate(numbers):
for idx2, elem2 in
enumerate(numbers):
if idx != idx2:
distance = abs(elem - elem2)
if distance < threshold:
return True

return False
```

Evaluating the answer

```
assert candidate([1.0, 2.0, 3.9, 4.0, 5.0,
2.2], 0.3) == True
assert candidate([1.0, 2.0, 3.9, 4.0, 5.0,
2.2], 0.05) == False
assert candidate([1.0, 2.0, 5.9, 4.0, 5.0],
0.95) == True
assert candidate([1.0, 2.0, 5.9, 4.0, 5.0],
0.8) == False
assert candidate([1.0, 2.0, 3.0, 4.0, 5.0,
2.0], 0.1) == True
assert candidate([1.1, 2.2, 3.1, 4.1, 5.1],
1.0) == True
assert candidate([1.1, 2.2, 3.1, 4.1, 5.1],
0.5) == False
```

HumanEval

164 courts problème en python

Dans le premier paper sur Codex de OpenAI

Handwritten

DS1000

Prompt

I have a dataframe with column names, and I want to find the one that contains a certain string, but does not exactly match it. I'm searching for 'spike' in column names like 'spike-2', 'hey spike', 'spiked-in' (the 'spike' part is always continuous). I want the column name to be returned as a string or a variable, so I access the column later with df['name'] or df[name] as normal. I want to get a list like['spike-2', 'spiked-in']. I've tried to find ways to do this, to no avail. Any tips?

```
import pandas as pd data =
{'spike-2': [1,2,3], 'hey spke':
[4,5,6], 'spiked-in': [7,8,9], 'no':
[10,11,12]}
df = pd.DataFrame(data)
s = 'spike'
```

A potential answer

```
result = [col for col in
df.columns if s in col
and col != s]
```

Evaluating the answer

```
data = {'spike-2': [1,2,3], 'hey
spke': [4,5,6], 'spiked-in':
[7,8,9], 'no': [10,11,12],
'spike': [13,14,15]}

df = pd.DataFrame(data)
s = 'spike'

ans = [col for col in df.columns
if s in col and col != s]


assert result == ans
```

DS1000

1000 data science problems, focused on data science libraries and problems

Sourced from StackOverflow

MBPP

Prompt

```
Write a function to find the similar elements from the given two tuple lists.
```

A potential answer

```
def similar_elements(test_tup1, test_tup2):
res = tuple(set(test_tup1) & set(test_tup2))
return (res)
```

Evaluating the answer

```
"assert similar_elements((3, 4, 5, 6),(5, 7, 4, 10)) == (4, 5)",
"assert similar_elements((1, 2, 3, 4),(5, 4, 3, 7)) == (3, 4)",
"assert similar_elements((11, 12, 14, 13),(17, 15, 14, 13)) == (13, 14)"
```

MBPP

974 courts problèmes en Python

crowd-sourced (donc *handwritten*-ish)

Google Research

Table 2.1: Popular datasets for code generation

Dataset	Number of Problems	Data Source	Repository Specific
HumanEval	164	Hand-Written	No
MBPP	974	Hand-Written	No
MTPB	115	Hand-Written	No
APPS	10 000	Competitions	No
CodeContests	117	Competitions	No
JulCe	1 518 049	Notebooks	No
DSP	1119	Notebooks	Yes
CoNaLa	2879	StackOverflow	Yes
DS-1000	1000	StackOverflow	Yes

Ce que les benchmarks réussisent

- permettes d’avoir une vision rapide pour comparer les différents modèles

Une checklist pour savoir si la note donné à un modèle est représentatif de sa qualité

Qui a run le test?

Qui a construit le dataset pour le test?

Est-ce qu’on a run le meme test plusieurs fois pour le même modèle?

Quel est la grosseur du dataset?

Qu’est-ce que le dataset test?

Comment est-ce qu’on vérifie si la génération du modèle est bonne ou non?

Est-ce qu’il se pourrait que le train dataset se retrouve dans le test set?

Évaluation avec tests cachés

Il existe des benchmarks cachés

Meilleur façon de s’assurer que les tests cachés ne se retrouve pas dans le training set

Et quand c’est toi qui construis ton agent?

- régression alerts
- benchmarking, pour te comparer

JetScale

Accueil Produit À propos Docs EN Voir la démo

JetScale AI lève 5,4 M$ pour réinventer l'ingénierie cloud En savoir plus

Optimisation infonuagique en mode autopilote livrée sous forme de code révisable

JetScale identifie en continu les inefficiences de votre environnement cloud et les transforme en correctifs de remédiation (Terraform) que votre équipe peut réviser, versionner et déployer via votre processus habituel.

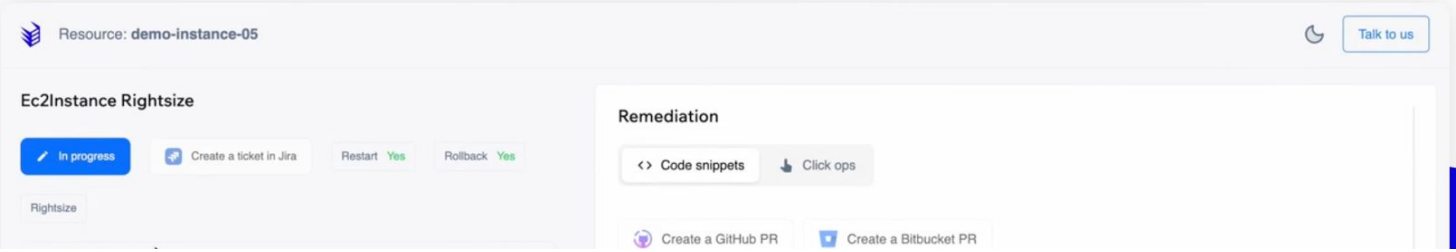

Check si ton modèle a des accès à la même info que les autres modèles

whats the lowest score thats good enough

ablation

benchmarks is expensive